



US

UNIVERSIDAD
DE SEVILLA

· 1505 ·

Asistente por voz para recuperación de información técnica en entornos industriales

Procesamiento del Lenguaje Natural
Curso 2026

Nombres	UVUS
Liborio Ángel Román Montes	librommon
Manuel Olías López	manolilop
Andrés Rubio Ramos	andrubram
Nicolás Martínez Van der Looven	nicmarvan

Sevilla, 7 de junio de 2026

Índice

1. Justificación del dominio	2
2. Caracterización lingüística del problema	2
2.1. Ambigüedad en múltiples niveles	2
2.2. Fenómenos específicos de los distintos canales	2
2.3. Complejidad multilingüe	3
3. Descomposición en tareas PLN	3
4. Restricciones no técnicas	4
5. Hipótesis de diseño inicial	5
6. Revisiones respecto a la Entrega 1	6
7. Decisiones de representación y modelado	6
7.1. Representación textual	6
7.2. Selección de modelo para la PoC (tareas T2, T3, y T4)	7
8. Datos y evaluación	8
8.1. Dataset seleccionado para la PoC	8
8.2. Métricas y criterio de éxito	9
9. Arquitectura final	9
9.1. Diagrama del sistema	9
9.2. Descripción textual del flujo	10
9.3. Justificación de la PoC: T2 + T3 + T4	12
10. Implementación	13
11. Evaluación y resultados	13
11.1. Recuperación documental	14
11.2. Latencia del ciclo T2–T4	14
11.3. Ejemplos cualitativos	15
12. Análisis de errores	15
13. Reflexión crítica	16
14. Referencias	17

1 | Justificación del dominio

En entornos industriales complejos (como pueden ser salas blancas, mantenimiento de torres de alta tensión o aerogeneradores, talleres especializados, etc.), el personal cualificado se enfrenta a una gran variabilidad de equipos y normativas de seguridad a menudo muy estrictas que prohíben depender exclusivamente de la memoria. Durante las intervenciones, es habitual que los operarios necesiten consultar datos críticos bajo demanda (por ejemplo, códigos de error específico o pasos de procedimientos infrecuentes). Sin embargo, en según que contexto es común que los equipos de protección o la necesidad de mantener las manos y la vista en la tarea en cuestión hagan que el acceso tradicional a estos manuales o esquemas técnicos sea inviable en el momento exacto en el que se necesita el dato. Adicionalmente, es común que la información contenida en los manuales se presente en un idioma (comúnmente en inglés) diferente al que habla el personal (español).

Las soluciones actuales dejan problemas críticos sin resolver en este dominio. Las interfaces táctiles o teclados fuerzan al operario a detener su trabajo, rompiendo la esterilidad o comprometiendo la seguridad. Por su parte, las interfaces de voz existentes basadas en comandos rígidos son insuficientes para consultas complejas, y los buscadores tradicionales por palabras clave se limitan a devolver el documento o la página entera. Esto obliga al usuario a leer o escuchar pasajes larguísimos hasta aislar el dato exacto, provocando sobrecarga cognitiva y frustración en un entorno donde el tiempo y la precisión son vitales.

El dominio es especialmente adecuado para PLN por varias razones críticas. En primer lugar, por la fuerte asimetría de registro: un buscador léxico tradicional fracasa al intentar mapear la economía expresiva y las referencias contextuales del operario con la sintaxis formal de los manuales. En segundo lugar, por la necesidad de productividad lingüística; los sistemas de voz basados en comandos rígidos no pueden abarcar la infinitud de consultas complejas posibles durante una intervención. Finalmente, por la necesidad de extraer el significado denotativo exacto: frente a técnicas que devuelven manuales completos, el PLN permite aislar la información pertinente y verbalizarla de forma concisa.

2 | Caracterización lingüística del problema

Antes de plantear cualquier solución técnica, es imprescindible entender qué propiedades del lenguaje natural hacen este dominio difícil para el procesamiento automático.

2.1 | Ambigüedad en múltiples niveles

El procesamiento de las consultas orales en entornos industriales presenta ambigüedades en varios niveles de análisis lingüístico:

- Nivel acústico y fonético: El canal vocal-auditivo sufre una severa degradación por el ruido ambiente, por ejemplo de la maquinaria, lo que agrava la ambigüedad acústica: “código B-60” frente a “código D-60”.
- Nivel léxico: El vocabulario especializado aísla significados concretos frente al uso común. Términos como “planta” (instalación vs. vegetal) o “gato” (herramienta vs. animal) exigen desambiguación contextual.
- Nivel sintáctico y pragmático: Bajo presión física, los operarios usan oraciones elípticas (“Error 404 bomba tres”). Actos de habla como “dime el paso siguiente” dependen totalmente del contexto y de la intención comunicativa.

2.2 | Fenómenos específicos de los distintos canales

La interacción por voz frente a la lectura de manuales presentan características propias que crea un fuerte desajuste estructural:

- Economía expresiva frente a formalidad: Las consultas orales aplican una fuerte economía expresiva, con frases cortas y sencillas, mientras que los manuales poseen un registro muy formal con estructuras sintagmáticas complejas y recursivas.

- **Evanescencia de la señal:** Las señales lingüísticas orales son temporales y desaparecen rápidamente. La respuesta sintetizada del sistema no puede ser un texto largo, sino que debe extraer y verbalizar la información requerida por el operario.
- **Desajuste referencial e inferencia pragmática:** A menudo, el operario no verbaliza la nomenclatura técnica exacta, recurriendo a términos coloquiales o describiendo una pieza por su función y contexto espacial (“la válvula de la izquierda” o “la tapa que sella el tanque”). El sistema no puede depender únicamente del significado léxico superficial; debe ser capaz de realizar inferencias apoyadas en el conocimiento del mundo a través de las referencias técnicas y la situación comunicativa.

2.3 | Complejidad multilingüe

El multilingüismo en este dominio va más allá de procesar idiomas por separado:

- **Préstamos y code-switching:** Es común mezclar términos en una misma frase (“El switch principal está en fault”) al interactuar con documentación externa.
- **Asimetría tecnológica:** Mientras los manuales técnicos en inglés cuentan con un nivel excelente de soporte tecnológico, extraer semánticamente esa información para sintetizar respuestas precisas en el idioma del operario (español) presenta un desafío de la disparidad de recursos.

3 | Descomposición en tareas PLN

El análisis del dominio descrito previamente revela que el sistema debe abordar un conjunto de tareas interdependientes, con distintos requisitos técnicos y diferentes prioridades operacionales. La descripción de estas tareas se recoge en la Tabla 3.1.

Tarea	Descripción	Prioridad
T1: Reconocimiento automático del habla (STT)	Transcripción de la señal de voz del operario a texto, incluyendo vocabulario técnico y posibles condiciones adversas (ruido, acentos, terminología específica).	Muy alta
T2: Interpretación semántica de la consulta	Traducción a inglés, normalización de la consulta e identificación de la intención del usuario, resolviendo ambigüedades léxicas y sintácticas.	Alta
T3: Recuperación de información (RAG)	Búsqueda y ordenación de fragmentos de documentos relevantes a la consulta en la base de conocimiento.	Muy alta
T4: Síntesis de respuesta en lenguaje natural	Generación y traducción de una respuesta clara, concisa y adaptada al contexto e idioma operativo, evitando información redundante o innecesaria.	Alta
T5: Síntesis de voz (TTS)	Conversión de la respuesta textual en audio inteligible y rápido, adecuado para su uso en entornos industriales.	Muy alta

Cuadro 3.1: Descomposición en las tareas PLN que describen el sistema junto a su descripción y prioridad.

Las tareas no son independientes: **T1 habilita el resto del sistema**, ya que una transcripción incorrecta compromete toda la cadena de procesamiento. A continuación, **T2 debe ejecutarse antes de T3**, puesto que la calidad de la recuperación depende de una correcta interpretación semántica de la consulta. Finalmente, **T4 y T5 dependen directamente de la salida de T3**, transformando la información recuperada en una respuesta útil y accesible para el operario.

Este flujo de dependencias define una arquitectura secuencial donde los errores pueden propagarse, lo que implica la necesidad de robustez en las primeras etapas.

4 | Restricciones no técnicas

El análisis del escenario de uso revela un conjunto de restricciones legales, éticas y operacionales que deben incorporarse como criterios de diseño desde el principio. Estas restricciones no afectan por igual a todas las tareas, sino que condicionan de forma distinta a T1–T5.

- **Trazabilidad de la respuesta.** La salida del sistema debe ser verificable, no solo plausible. Esta restricción afecta sobre todo a **T3** y **T4**: la recuperación no puede limitarse a devolver una respuesta generada, sino que debe conservar la evidencia documental en la que se apoya, y la síntesis final debe poder remitir al documento, sección o fragmento relevante. En un entorno técnico, una respuesta no trazable reduce la confianza del usuario y dificulta la validación de la información recuperada.
- **RGPD, privacidad y uso de APIs externas.** Aunque la PoC pueda construirse con documentación pública, el escenario de uso real presupone consultas de voz, transcripciones, historiales de interacción y, potencialmente, documentación interna. Esta restricción afecta de forma directa a **T1**, **T2** y **T3**, ya que parte de la señal de entrada y del contexto recuperado podría enviarse a APIs externas. Por tanto, el sistema debe minimizar los datos transmitidos, evitar fragmentos documentales innecesarios en cada llamada y limitar la persistencia de audio, transcripciones y logs a lo estrictamente necesario.
- **Sesgo lingüístico y asimetría multilingüe.** Es plausible que el usuario interactúe en español mientras una parte de la documentación técnica y de los modelos disponibles esté en inglés. Esta restricción afecta especialmente a **T1**, **T2** y **T3**. En **T1**, porque el reconocimiento de habla puede degradarse con acentos, ruido o terminología híbrida; en **T2**, porque la interpretación semántica debe normalizar consultas formuladas en español coloquial o con mezcla de lenguas; y en **T3**, porque la recuperación puede depender de documentación técnica en inglés aunque la necesidad informativa del operario se exprese en español. Este sesgo debe medirse explícitamente.
- **Latencia.** El sistema se utilizará durante una tarea manual, por lo que una respuesta lenta pierde gran parte de su utilidad. Esta restricción es especialmente crítica en **T1**, **T2** y **T5**, que forman la parte más interactiva de la pipeline. Si la transcripción tarda demasiado, si la interpretación semántica introduce espera o si la respuesta hablada no se produce con rapidez, la interacción deja de ser operativa. **T3** y **T4** también están condicionadas por la latencia, aunque con algo más de margen, ya que de ellas depende la calidad de la respuesta final.
- **Seguridad operativa y coste del error.** En este dominio, una respuesta incorrecta no tiene solo un coste informativo: puede inducir una actuación errónea, comprometer la seguridad o provocar una intervención fuera de procedimiento. Esta restricción afecta principalmente a **T2**, **T3** y **T4**. Una mala interpretación de la consulta en **T2** puede arrastrar toda la cadena. Una recuperación errónea en **T3** puede seleccionar evidencia irrelevante. O incluso una síntesis excesivamente confiada en **T4** puede convertir una ambigüedad en una instrucción aparentemente clara.
- **Carga cognitiva e inteligibilidad.** La utilidad del sistema no depende solo de recuperar información correcta, sino de presentarla de forma utilizable en un entorno de trabajo. Esta restricción afecta especialmente a **T4** y **T5**. La respuesta textual debe ser breve, inequívoca y adaptada al contexto operativo, evitando párrafos largos o detalles redundantes. Además la conversión a voz debe mantener claridad, ritmo adecuado e inteligibilidad incluso cuando la información original proviene de manuales escritos para lectura visual, no para escucha.

En conjunto, estas restricciones justifican que el sistema deba diseñarse no solo para comprender el lenguaje natural, sino para hacerlo de forma verificable, privada, multilingüe, segura y útil en condiciones operativas reales.

5 | Hipótesis de diseño inicial

Con el análisis lingüístico y el mapa de restricciones establecidos, formulamos hipótesis iniciales sobre el enfoque técnico más adecuado para cada tarea. Estas hipótesis son provisionales y se revisarán en la Entrega 2.

- **T1 (reconocimiento automático del habla): paradigma neuronal ligero con ejecución local.** La transcripción de consultas en un entorno ruidoso, con vocabulario técnico y abundancia de tokens alfanuméricos, exige un modelo de ASR más robusto que los sistemas de propósito general. Nuestra hipótesis inicial es utilizar un sistema ligero desplegable localmente, ya que esto permite mantener una latencia razonable y reducir la dependencia de red en la primera etapa del sistema.
- **T2 (interpretación semántica de la consulta): paradigma neuronal generativo mediante API.** La normalización de consultas elípticas, deícticas o formuladas en registro coloquial requiere capacidades de inferencia semántica difíciles de capturar con reglas o modelos clásicos. Por ello, nuestra hipótesis inicial es que T2 encaja mejor en un modelo generativo accesible por API, capaz de reformular la consulta del operario en una representación más útil para la recuperación.
- **T3 (recuperación de información mediante RAG): enfoque híbrido léxico-semántico.** Dado que la consulta se traduce al inglés tras T2 y puede no coincidir exactamente con la terminología del manual, una búsqueda puramente léxica o puramente semántica resulta insuficiente. Por ello, proponemos un enfoque híbrido que combine búsqueda por palabras clave con embeddings, aprovechando tanto la precisión en términos técnicos como la capacidad de generalización semántica para mejorar la recuperación.
- **T4 (síntesis de respuesta en lenguaje natural): paradigma neuronal generativo condicionado por evidencia.** La respuesta final no debe limitarse a copiar un fragmento del manual, sino que debe condensar la información recuperada en una instrucción breve, clara y adecuada al canal oral. Esto sugiere un enfoque generativo, aunque condicionado explícitamente por la evidencia recuperada en T3 para mantener trazabilidad y reducir el riesgo de alucinación.
- **T5 (síntesis de voz): paradigma neuronal TTS gratuito y de ejecución local.** La conversión final a audio debe ser suficientemente inteligible para resultar útil en una interacción manos libres, aunque no alcance la naturalidad de sistemas comerciales más avanzados. Nuestra hipótesis inicial es utilizar un modelo TTS gratuito y local, priorizando facilidad de integración y coste nulo sobre calidad prosódica máxima.

6 | Revisiones respecto a la Entrega 1

Tras estudiar los modelos estadísticos, vectoriales y neuronales vistos durante el curso, se revisan varias de las hipótesis planteadas en la Entrega 1. En general, se mantiene la estructura funcional del sistema, aunque se concretan algunos modelos y se reorganizan determinadas tareas para mejorar la modularidad y adaptarse mejor a las restricciones identificadas previamente.

■ T1 (reconocimiento automático del habla): se confirma y se concreta.

Se mantiene la hipótesis de utilizar un modelo neuronal ligero con ejecución local para la transcripción de consultas orales en entornos ruidosos. La propuesta se concreta mediante el uso de **Whisper base** o **Whisper small**, modelos capaces de mantener robustez frente a ruido, acentos y terminología técnica.

■ T2 (interpretación semántica de la consulta): se modifica.

La tarea se reorganiza en dos subtarefas diferenciadas: una primera etapa de normalización de la consulta en lenguaje natural y una segunda etapa de traducción del español al inglés. Ambas operaciones se realizarán mediante un LLM multilingüe.

Además, se revisa la hipótesis inicial de utilizar modelos externos accesibles mediante API. Debido a las restricciones de privacidad y RGPD identificadas en la Entrega 1, se prioriza el uso de modelos desplegables localmente para evitar el envío innecesario de transcripciones o fragmentos documentales a servicios externos. Además, en entornos donde la conexión a internet resulte limitada o imposible, la decisión de utilizar un modelo local permite el despliegue del sistema en equipos locales *on site*.

■ T3 (recuperación de información mediante RAG [4]): se modifica.

Inicialmente se planteó comparar distintos enfoques léxico-semánticos para la recuperación de información. Finalmente, se opta por una comparación más concreta entre un modelo puramente léxico y un modelo híbrido léxico-semántico, permitiendo evaluar de forma más clara el impacto de incorporar información semántica en la recuperación.

■ T4 (síntesis de respuesta en lenguaje natural): se modifica.

La tarea de generación de respuestas también se divide en dos subtarefas. Primero, un modelo generativo, en principio el mismo seleccionado para T2, producirá una respuesta en inglés utilizando la pregunta normalizada y la evidencia recuperada por T3. Posteriormente, esa respuesta será traducida al español para adaptarla al idioma operativo del usuario.

Esta separación permite mantener trazabilidad sobre la información utilizada y simplifica el flujo multilingüe del sistema.

■ T5 (síntesis de voz): se confirma y se concreta.

Se mantiene la hipótesis de utilizar un sistema TTS gratuito y de ejecución local para generar respuestas orales inteligibles en español. La propuesta se concreta mediante **Piper TTS**, priorizando baja latencia, facilidad de integración y funcionamiento offline frente a soluciones comerciales más complejas.

7 | Decisiones de representación y modelado

A continuación, se detallan y justifican las representaciones textuales elegidas para cada una de las tareas del sistema. En cada caso, la decisión de representación se ajusta al tipo de modelo propuesto:

7.1 | Representación textual

- **T1.** La petición de los operarios se recibe como una señal acústica. El modelo de *Speech-to-Text* (STT) procesa el espectrograma de audio y devuelve una tokenización de la consulta, la cual se convierte posteriormente a texto en lenguaje natural (español). Si tuviéramos control absoluto sobre la arquitectura del sistema, se podría garantizar que las tokenizaciones usadas por el STT y el LLM

de **T2** fuesen la misma. De esta manera, se omitiría la conversión a lenguaje natural y **T2** recibiría directamente la secuencia de tokens, reduciendo así la latencia del sistema.

Se ha planteado también la posibilidad de utilizar herramientas STT que gestionen también la traducción al inglés mediante el uso de una arquitectura *encoder-decoder*, lo que simplificaría la secuencia de tareas y reduciría la latencia. Sin embargo, se ha decidido no implementarlo de esta manera; se considera conveniente normalizar la petición antes de traducirla y emplear un LLM para evitar la traducción errónea de tecnicismos o nombres propios relativos a la industria.

- **T2.** Esta tarea recibe la petición del operario en lenguaje natural (español). Aquí, un LLM debe encargarse, en primer lugar, de normalizar la consulta y, en segundo lugar, de traducirla al inglés para facilitar el trabajo de **T3**, que operará con manuales de documentación en dicho idioma. El uso de un LLM y la representación textual escogida responden a que, generalmente, las peticiones serán breves y carecerán de contexto. Cualquier modelo que no reciba información previa para entender el contexto podría normalizar o traducir la petición de manera errónea.
- **T3.** Para el sistema RAG se utiliza una representación híbrida de los datos. Por un lado, el enfoque léxico utiliza vectores dispersos (*Bag of Words*) y, por otro, el enfoque semántico emplea vectores densos o *embeddings* contextuales. El enfoque léxico permite recuperar información literal, como nombres propios de piezas o códigos de error, mientras que el semántico captura la intención cuando se emplea un vocabulario funcional o descriptivo. El sistema RAG utilizará ambas representaciones, junto con los manuales divididos en fragmentos (*chunks*), para calcular una puntuación de relevancia por fragmento. Esta puntuación combinará la coincidencia léxica obtenida mediante BM25 con la similitud semántica derivada de los embeddings, permitiendo ordenar los fragmentos según su utilidad esperada para responder a la petición.
- **T4.** Esta tarea recibe la petición normalizada en inglés de **T2** junto con los K *chunks* más relevantes determinados por **T3** (K es un hiperparámetro del sistema) y emplea de nuevo un LLM para generar una respuesta clara, concisa y de carácter imperativo. La respuesta obtenida en inglés será procesada nuevamente por el LLM para que, junto a la petición original en español, se obtenga una traducción al castellano consistente. El uso del LLM y la descomposición en estas dos sub tareas garantizan una respuesta coherente y con el contexto necesario, evitando acumular errores de la traducción inicial. Aunque esto incrementa el coste computacional, en esta fase la precisión y la seguridad operativa son críticas: una alucinación podría provocar un accidente en el entorno industrial. La alta capacidad lógica del LLM minimiza este riesgo.
- **T5.** La respuesta final de **T4** en español es convertida en un señal acústica. La herramienta TTS empleada tendrá un coste computacional mínimo. Esta elección refleja una decisión operativa clave donde se sacrifica la naturalidad y la expresividad hiperrealista en favor de una menor latencia. En un entorno industrial ruidoso, la naturalidad emocional es prescindible; lo vital es la inteligibilidad y la velocidad de respuesta.

7.2 | Selección de modelo para la PoC (tareas T2, T3, y T4)

Las tareas que se implementarán en la PoC son **T2**, **T3** y **T4** (las tareas **T1** y **T5** no forman parte de la idea central del proyecto). Los modelos seleccionados son:

- **T2 y T4.** Debido a la privacidad de los manuales y de las peticiones, las tareas **T2** y **T4** emplearán un LLM desplegado localmente. Se ha seleccionado el modelo **Ministral 3 8B** [5] por ser un modelo público europeo con una alta capacidad de razonamiento lógico y relativamente pequeño.
- **T3.** Se comparan dos candidatos para esta tarea: uno que prioriza la baja carga computacional y otro que prioriza la correcta interpretación de la consulta.
 1. **Candidato A: BM25.** Emplea un enfoque estrictamente léxico pero muy eficiente computacionalmente. La selección de **BM25** [8] frente al clásico **TF-IDF** se debe a que el primero introduce medidas para la saturación de la frecuencia de términos y una normalización de longitud de documento más sofisticada. Este enfoque establece un *baseline* para el segundo candidato.

2. **Candidato B: BM25 + jina-embeddings-v2-base-en.** Este candidato se propone como una mejora del anterior combinando el enfoque léxico y el semántico. Utiliza el modelo de *embeddings* **jina-embeddings-v2-base-en** [3]. Este modelo se ha seleccionado por utilizar *embeddings* contextuales, ser un modelo monolingüe en inglés, basarse en la arquitectura **BERT** y permitir secuencias de hasta 8192 tokens. Para obtener el ranking final, los resultados recuperados mediante BM25 y búsqueda vectorial se combinarán mediante una estrategia de fusión de rankings, concretamente *Reciprocal Rank Fusion* (RRF) [2]. Esta elección permite integrar ambas listas sin comparar directamente puntuaciones de naturaleza distinta, priorizando los fragmentos que aparecen bien posicionados en ambos métodos. Este enfoque híbrido permite captar de una manera más fiel la intención de la petición, a pesar del mayor coste computacional y del incremento en la latencia del sistema.

La PoC implementará ambos candidatos y ofrecerá una comparación bajo unas mismas condiciones de evaluación. Se pretende cuantificar de manera realista el equilibrio entre coste y rendimiento que ofrece el enfoque híbrido frente al enfoque léxico tradicional.

8 | Datos y evaluación

8.1 | Dataset seleccionado para la PoC

Para desarrollar una PoC que se ajuste a las decisiones de diseño y el ámbito de aplicación descrito, se ha decidido recurrir a documentación de maquinaria industrial real. En particular, utilizaremos como fuente principal para la recuperación de información el manual técnico de *Siemens SINUMERIK 808D ADVANCED Diagnostics Manual* [9]. Esta guía está diseñada para la identificación y resolución de errores en sistemas de control numérico (CNC), e incluye capítulos críticos sobre el manejo de la interfaz, mantenimiento, actualización del sistema y gestión de alarmas, etc.

Para el procesamiento del documento, emplearemos **LlamaParse** [6], lo que nos permitirá obtener una representación estructurada y limpia, facilitando su manejo frente al formato PDF convencional. No se limita a realizar un simple OCR, sino que analiza la estructura semántica y visual del documento. Por un lado, emplea análisis basado en visión para identificar la disposición espacial de los elementos, añadiendo descripciones a imágenes o diagramas y, de forma crucial, reconstruyendo la estructura de las tablas. De este modo, la salida no es un flujo de texto plano, sino un documento en formato Markdown que captura las jerarquías y la estructura lógica del manual. Esta característica es fundamental para una segmentación (chunking) más natural y efectiva. En lugar de aplicar una división arbitraria por número de caracteres o páginas, la estructura obtenida permite una segmentación orientada al contenido. Por ejemplo, en las secciones que catalogan las alarmas del sistema, es posible configurar el sistema para generar un *chunk* independiente por cada código de error descrito. Esto garantiza que el contexto de la solución no se fragmente, mejorando drásticamente la precisión de la recuperación en el sistema RAG.

Por otro lado, para validar el sistema, es necesario disponer de un conjunto de peticiones asociadas a los extractos del documento donde se encuentra la respuesta. Planteamos una técnica de generación sintética de este dataset de pares (petición/chunks) basada en modelos LLM como *Gemini* o *ChatGPT*. A través de una serie de prompts específicos, el chatbot generará estas consultas y referenciará los fragmentos correspondientes, permitiéndonos evaluar la precisión del sistema RAG. Con el fin de diversificar el dataset, se definirá una taxonomía de consultas basada en cuatro o cinco categorías técnicas: navegación y configuración del sistema, resolución de alarmas específicas, límites técnicos o de seguridad, y procedimientos de backup o gestión de datos, etc. A partir de estos patrones, se solicitará al LLM la generación de peticiones específicas que deben estar estrictamente vinculadas a k fragmentos (chunks) reales del manual.

Para garantizar la fiabilidad de este dataset sintético, se implementará un proceso de validación cruzada. Este consistirá en solicitar al modelo (en una sesión independiente) que identifique los fragmentos que dan respuesta a las peticiones generadas previamente. Si el contenido recuperado no coincide con los fragmentos originales de referencia, la petición se marcará como ambigua. Finalmente, estas consultas ambiguas serán sometidas a una revisión manual para ser refinadas o descartadas.

Nota Legal: Esta PoC ha sido desarrollada exclusivamente con fines educativos para la asignatura *Procesamiento del Lenguaje Natural* del Máster *Computación, Lógica e Inteligencia Artificial* de la

Universidad de Sevilla. No existe relación comercial con *Siemens AG*. El documento utilizado es de acceso público y su procesamiento se realiza con motivos puramente académicos bajo la excepción de ilustración para la enseñanza.

8.2 | Métricas y criterio de éxito

Para cuantificar la eficacia de la PoC desarrollada, se llevará a cabo una evaluación de cada modelo según las siguientes métricas:

- **Latencia:** Se medirá el tiempo de respuesta de extremo a extremo. Esta métrica es crítica en entornos industriales, donde el acceso rápido a la información técnica puede determinar el tiempo de inactividad de una máquina.
- **Capacidad de Recuperación:** Para cuantificar la eficacia de la PoC desarrollada, se llevará a cabo una evaluación de cada modelo utilizando métricas estándar de Recuperación de Información [7]:
 1. **Recall@k:** Ratio entre el número de fragmentos relevantes encontrados en los k primeros resultados recuperados y el total de fragmentos relevantes para la consulta. Puesto que el orden no es determinante para esta métrica, captura únicamente la capacidad del sistema para descubrir correctamente el conjunto de resultados necesarios. Es una métrica de gran interés cuando una petición requiere de varios fragmentos dispersos para generar una respuesta completa.
 2. **Mean Average Precision (MAP):** Calcula el promedio de la precisión en cada posición donde se encuentra un fragmento relevante. Proporciona una medida más refinada al considerar la posición ocupada por dichos fragmentos; cuanto más cerca de las primeras posiciones se sitúen las respuestas relevantes, mayor será la puntuación del sistema.

Aunque el diseño inicial contempla la posibilidad de asociar varios fragmentos a cada petición, es posible que la complejidad de generar un dataset sintético con múltiples referencias resulte inabarcable. En dicho escenario, se optará por simplificar el conjunto de datos a un único fragmento relevante por consulta. De ser así, se emplearán el Hit Rate@k y el Mean Reciprocal Rank (MRR); métricas análogas al Recall@k y al MAP cuando el ground truth consiste en un único elemento de referencia en lugar de un conjunto de ellos.

Además, planteamos comparar la capacidad de los modelos al usar únicamente el texto extraído mediante OCR y segmentado uniformemente frente al documento bien formateado y procesado a través de *Llama-Parser*, con el fin de mostrar las ventajas de un buen preprocesamiento del documento.

El criterio de éxito para esta PoC no reside en alcanzar el estado del arte, sino en demostrar que la implementación del método híbrido ofrece una mejora significativa frente a los modelos puramente vectoriales. Asimismo, se pretende validar que un procesamiento avanzado del documento, basado en la preservación de estructuras jerárquicas y tablas, permite una recuperación de información más precisa, contextualizada y de mayor calidad técnica.

9 | Arquitectura final

La arquitectura final del sistema se plantea como una cadena de procesamiento secuencial orientada a transformar una consulta oral del operario en una respuesta breve, trazable y adaptada al canal de voz. El diseño mantiene la descomposición funcional en cinco tareas PLN, pero distingue dos niveles de alcance: por un lado, la arquitectura completa del sistema real; por otro, la prueba de concepto, centrada en las tareas T2, T3 y T4, que constituyen el núcleo lingüístico y documental del sistema.

9.1 | Diagrama del sistema

La Figura 9.1 muestra los principales componentes del sistema y los flujos de datos entre ellos. Se distingue entre el flujo de consulta en tiempo de ejecución y el flujo previo de preparación de la base documental.




Figura 9.1: Arquitectura final del sistema y flujos de datos entre tareas. Las flechas continuas representan el flujo principal de inferencia, mientras que las flechas discontinuas indican conexiones auxiliares necesarias para construir los prompts o acceder a la base documental.

9.2 Descripción textual del flujo

El sistema completo comienza con una consulta oral formulada por el operario en español. En primer lugar, T1 convierte la señal acústica en una transcripción textual. Esta salida todavía puede contener marcas propias del habla espontánea, elipsis, referencias deícticas o términos técnicos formulados de manera incompleta, por lo que no se utiliza directamente para recuperar información.

A continuación, T2 se divide en dos subtareas. La primera, T2a, normaliza la consulta en español: explicita la intención del usuario, mantiene los códigos técnicos y elimina ambigüedades superficiales cuando sea posible. La segunda, T2b, traduce la consulta normalizada al inglés, ya que la documentación técnica sobre la que opera el sistema se encuentra en este idioma. La salida principal de T2 es, por tanto, una consulta normalizada en inglés, pero se conserva también la consulta original en español para usarla más adelante en T4b.

Prompt de ejemplo para T2a: normalización de la consulta

Sistema: Eres un asistente especializado en normalizar consultas orales de operarios en un entorno industrial. Tu tarea es reescribir la consulta de forma clara, completa y precisa, sin responderla. Mantén códigos de error, nombres de piezas, siglas y referencias técnicas tal como aparecen. Si hay ambigüedad, conserva la formulación más prudente y no inventes información.

Entrada:

Consulta transcrita: “Error 700016 en el eje, qué hago ahora”

Salida esperada:

Consulta normalizada en español: “¿Qué procedimiento debe seguirse para resolver el error 700016 asociado al eje del sistema?”

Prompt de ejemplo para T2b: traducción de la consulta normalizada al inglés

Sistema: Traduce al inglés la consulta técnica normalizada. No añadas información nueva. Mantén sin traducir los códigos, referencias de alarma, nombres de parámetros y denominaciones técnicas que puedan aparecer literalmente en el manual.

Entrada:

Consulta normalizada en español: “¿Qué procedimiento debe seguirse para resolver el error 700016 asociado al eje del sistema?”

Salida esperada:

Normalized query in English: “What procedure should be followed to resolve error 700016 associated with the system axis?”

La consulta normalizada en inglés se envía a T3, que actúa como componente de recuperación de información. Esta tarea consulta la base documental previamente procesada: el manual técnico se convierte a una representación estructurada mediante *LlamaParse*, se segmenta en fragmentos o *chunks*, y se indexa tanto con una representación léxica como con una representación semántica. En la PoC se comparan dos alternativas: BM25 como línea base léxica y un sistema híbrido que combina BM25 con embeddings generados mediante *jina-embeddings-v2-base-en*. La salida de T3 es una lista ordenada de los *K* fragmentos más relevantes junto con sus metadatos de trazabilidad.

T4 también se divide en dos subtareas. En T4a, el LLM recibe la consulta normalizada en inglés y los fragmentos recuperados por T3. A partir de esa evidencia genera una respuesta breve en inglés, de carácter operativo y sin añadir información no sustentada por los fragmentos. En T4b, esa respuesta se traduce y adapta al español utilizando también la consulta original del operario. Esta conexión entre T2 y T4 es relevante porque permite que la traducción final no dependa solo de la respuesta inglesa, sino también de cómo el usuario formuló originalmente su necesidad.

Prompt de ejemplo para T4a: generación de respuesta en inglés basada en evidencia

Sistema: You are a technical assistant for industrial maintenance. Answer only using the provided manual excerpts. Produce a short, clear and operational answer. Do not invent steps. If the excerpts are insufficient, say that the manual evidence is not enough. Include the reference identifiers used.

Entrada:

Normalized query in English: “What procedure should be followed to resolve error 700016 associated with the system axis?”

Retrieved evidence:

REF:1 Chunk 12, section 3.4: ...

REF:2 Chunk 15, section 3.5: ...

REF:3 Chunk 18, section 4.1: ...

REF:4 Chunk 32, section 6.4: ...

REF:5 Chunk 4, section 1.1: ...

Salida esperada:

Answer in English: “Check the axis configuration and verify the drive status before restarting the operation. Follow the diagnostic procedure indicated for alarm 700016. [REF:1][REF:2]”

Finalmente, T5 convierte la respuesta textual final en español en una señal acústica mediante un sistema TTS local. En la arquitectura completa, esta etapa es necesaria para cerrar la interacción manos libres, aunque no forma parte del núcleo de la PoC.

Prompt de ejemplo para T4b: traducción y adaptación final al español

Sistema: Traduce y adapta al español la respuesta técnica. Debe sonar natural para un operario, ser breve y mantener un tono imperativo o instructivo. No añadas pasos nuevos. Conserva las referencias documentales. Usa la consulta original para mantener coherencia terminológica con el usuario.

Entrada:

Consulta original en español: “Error 700016 en el eje, qué hago ahora”

Respuesta en inglés: “Check the axis configuration and verify the drive status before restarting the operation. Follow the diagnostic procedure indicated for alarm 700016. [REF:1][REF:2]”

Salida esperada:

Respuesta final en español: “Comprueba la configuración del eje y verifica el estado del accionamiento antes de reiniciar la operación. Sigue el procedimiento de diagnóstico indicado para la alarma 700016. [REF:1][REF:2]”

9.3 | Justificación de la PoC: T2 + T3 + T4

La prueba de concepto se centrará en T2, T3 y T4 porque estas tareas concentran la parte más representativa del problema de PLN planteado. T1 y T5 son necesarias para un producto final plenamente operativo, pero pueden sustituirse en la PoC por entrada y salida textual sin alterar la pregunta técnica principal del proyecto: si una consulta breve en español puede normalizarse, traducirse, conectarse con documentación técnica en inglés y transformarse en una respuesta trazable, concisa y útil para el operario.

La elección de T2 es importante porque la recuperación depende directamente de la calidad de la consulta. Una transcripción literal como “error del eje qué hago” puede ser insuficiente para localizar el fragmento adecuado del manual, mientras que una consulta normalizada y traducida al inglés aproxima mejor la formulación del usuario al registro formal de la documentación técnica. Por tanto, T2 actúa como puente entre el lenguaje oral, breve y contextual del operario y el lenguaje escrito, técnico y formal de los manuales.

T3 constituye el núcleo documental de la arquitectura. Su implementación permite comparar de forma controlada un enfoque puramente léxico, basado en BM25, frente a un enfoque híbrido que añade embeddings contextuales. Esta comparación responde directamente a una de las decisiones de diseño más relevantes del sistema: determinar si el incremento de coste computacional del modelo semántico se justifica por una mejora real en la recuperación de fragmentos técnicos.

T4 completa la cadena porque transforma la evidencia recuperada en una respuesta accionable. No basta con devolver el fragmento del manual: el sistema debe sintetizarlo de forma breve, segura y comprensible para un usuario que está realizando una tarea manual. Además, al separar la generación de la respuesta en inglés y su posterior traducción al español, se mantiene el razonamiento sobre la evidencia en el idioma de la documentación y se adapta únicamente la salida final al idioma operativo del usuario.

En conjunto, la PoC T2+T3+T4 permite evaluar el componente central del sistema sin depender de la calidad del reconocimiento de voz ni de la síntesis de audio. Esto reduce el alcance de implementación sin simplificar artificialmente el problema lingüístico principal: la conexión entre consulta oral en español, documentación técnica en inglés, recuperación trazable y respuesta final adaptada al operario.

10 | Implementación

La prueba de concepto implementa las subtarefas T2, T3 y T4, dejando fuera T1 y T5. Esta decisión mantiene el foco en el núcleo lingüístico-documental del sistema: comprobar si una consulta breve en español puede normalizarse, traducirse, conectarse con documentación técnica en inglés y transformarse en una respuesta operativa y trazable. Las etapas de voz son necesarias para un producto final, pero no cambian la pregunta técnica principal de esta PoC.

$$\text{Consulta ES} \rightarrow T2_a \rightarrow T2_b \rightarrow T3 \rightarrow T4_a \rightarrow T4_b$$

En $T2_a$, el LLM normaliza la consulta original del operario en español. Esta etapa explicita la intención, mantiene códigos de alarma, nombres de piezas, siglas y parámetros, y evita responder a la consulta. En $T2_b$, la consulta normalizada se traduce al inglés, ya que el manual usado como base documental está escrito en ese idioma. T3 realiza la recuperación documental y devuelve los K fragmentos más relevantes con identificadores de referencia. Finalmente, $T4_a$ genera una respuesta técnica en inglés condicionada por la evidencia recuperada y $T4_b$ la traduce y adapta al español, conservando las referencias documentales.

La base documental corresponde al *Siemens SINUMERIK 808D ADVANCED Diagnostics Manual*. El PDF fue procesado con LlamaParse hasta obtener un Markdown estructurado. En fases anteriores se contempló comparar esta representación con una versión de texto plano u OCR segmentada uniformemente; en la implementación final esa comparación se descartó para mantener el experimento centrado en la decisión principal de recuperación. Así, BM25, recuperación vectorial e híbrida operan sobre los mismos chunks y cualquier diferencia de rendimiento se atribuye al método de recuperación, no al preprocesamiento. El *chunking* se diseñó como una estrategia estructural orientada al dominio. En lugar de dividir el texto solo por número de palabras o mediante clustering semántico, el sistema detecta bloques de alarma, conserva el identificador de alarma y subdivide el contenido por campos técnicos como explicación, reacción, remedio o continuación del programa. Esto evita mezclar alarmas diferentes y reduce el riesgo de recuperar fragmentos sin contexto. Los chunks finales se guardan en un JSONL versionado, que actúa como fuente canónica para reconstruir Weaviate con los mismos identificadores, textos y metadatos en cualquier equipo.

La recuperación implementa tres modos. BM25 actúa como referencia léxica fuerte, especialmente útil cuando la consulta contiene códigos exactos o terminología literal del manual. La recuperación vectorial usa embeddings BAAI/bge-base-en-v1.5 [1], calculados localmente. La recuperación híbrida combina los rankings BM25 y vectorial mediante Reciprocal Rank Fusion (RRF), lo que permite integrar evidencia léxica y semántica sin mezclar directamente puntuaciones de naturaleza distinta. El LLM utilizado en T2 y T4 es mistralai/Ministral-3-8B-Instruct-2512, ejecutado localmente. La alternativa inicial jina-embeddings-v2-base-en fue sustituida por BGE para simplificar dependencias y mantener un único entorno compatible con la pila de transformers necesaria para Ministral.

El repositorio incluye scripts para construir el índice, consultar T3, ejecutar el ciclo T2–T4, exportar chunks, generar consultas de evaluación y auditar latencias. También incluye documentación de chunking, evaluación y reproducción. Esta organización permite separar preparación documental, indexación, recuperación, generación y evaluación, facilitando que otros miembros del grupo puedan reconstruir la PoC sin depender del estado local de Weaviate. La reproducibilidad se trató como un requisito de implementación, no solo como una comodidad. Por eso la base vectorial no se reconstruye directamente desde el Markdown en cada equipo, sino desde el archivo JSONL procesado. Este archivo fija los `chunk.id`, el texto, la sección, los metadatos y la estrategia de chunking usada. Si se borra la instancia local de Weaviate, basta con levantar Docker e importar de nuevo ese JSONL para obtener la misma colección documental. Esta decisión evita que pequeñas diferencias en librerías, scripts o parámetros de segmentación generen índices incompatibles entre miembros del grupo.

11 | Evaluación y resultados

La evaluación automática de calidad se centra en T3, porque es la etapa para la que existe un conjunto de prueba con referencias documentales etiquetadas. La cadena completa T2–T4 se analiza de forma complementaria mediante latencia y ejemplos cualitativos. Esta distinción es importante: medir T3 permite comparar recuperadores de forma reproducible, mientras que revisar T2–T4 permite observar cómo los aciertos y fallos de recuperación afectan a la respuesta final.

11.1 | Recuperación documental

El conjunto de evaluación contiene 100 consultas generadas automáticamente con Groq a partir de chunks reales del manual. Cada ejemplo conserva el identificador del chunk de origen como referencia esperada, lo que permite construir un *ground truth* reproducible. Las consultas se distribuyen en 50 fáciles, 30 medias y 20 difíciles. Las fáciles mantienen vocabulario cercano al manual; las medias introducen reformulaciones; y las difíciles omiten información o expresan el problema de forma indirecta. Como cada consulta tiene un único chunk relevante, se emplean *Hit Rate@5* y MRR.

Este dataset no pretende cubrir toda la variabilidad de un entorno real, sino proporcionar una primera prueba controlada del recuperador. Su principal ventaja es que todas las preguntas proceden de chunks activos en la misma base documental usada por la PoC. Su principal limitación es que la relevancia se reduce a un único fragmento esperado, cuando en un manual técnico pueden existir respuestas parcialmente distribuidas entre explicación, remedio, reacción del sistema y continuación del programa. Por tanto, las métricas deben interpretarse como una evaluación de localización documental, no como una medida completa de calidad conversacional.

Cuadro 11.1: Resultados de recuperación. Las tres últimas columnas muestran *Hit Rate@5* por dificultad.

Método	Hit@5	MRR	Fácil	Media	Difícil
BM25	0.83	0.741	0.98	0.70	0.65
Vectorial (BGE)	0.87	0.783	0.94	0.93	0.60
Híbrido	0.87	0.769	0.96	0.87	0.65

La recuperación vectorial obtiene el mejor rendimiento global, con *Hit Rate@5*=0.87 y MRR=0.783. El sistema híbrido iguala el *Hit Rate@5*, aunque queda ligeramente por debajo en MRR. BM25 es muy competitivo en consultas fáciles, donde los identificadores y términos coinciden con el manual, pero cae en dificultad media al depender de coincidencias léxicas. Esta diferencia confirma una de las hipótesis del diseño: la recuperación puramente léxica no basta cuando la formulación del usuario se aleja del registro documental.

La lectura por dificultad aporta matices. En consultas fáciles, BM25 alcanza 0.98, lo que indica que la coincidencia literal sigue siendo muy valiosa en un dominio con códigos y nombres técnicos. En consultas medias, BGE sube a 0.93 frente a 0.70 de BM25, mostrando que los embeddings ayudan cuando hay paráfrasis o expresiones menos literales. En consultas difíciles, todos los enfoques se sitúan entre 0.60 y 0.65, señal de que el problema principal no es solo elegir modelo, sino discriminar entradas muy próximas dentro de familias de alarmas similares.

También es relevante distinguir *Hit Rate@5* y MRR. *Hit Rate@5* indica si el fragmento correcto aparece entre los cinco candidatos que se entregan a T4, lo que es importante porque el LLM puede seleccionar evidencia dentro de una ventana corta. MRR, en cambio, penaliza que el fragmento correcto aparezca en posiciones bajas. Para esta PoC ambas métricas son complementarias: *Hit Rate@5* mide si T4 tiene oportunidad de responder bien, mientras que MRR mide cuánto ruido tiene que superar para hacerlo.

11.2 | Latencia del ciclo T2–T4

La latencia extremo a extremo se midió con cinco consultas en español, recuperación híbrida, *top-k*=5 y temperatura 0, usando una GPU AMD Radeon RX 9070XT con 16GB de VRAM. La carga inicial de modelos fue de 23,98 s y se midió aparte; los valores reportados corresponden al procesamiento de consultas una vez inicializado el sistema.

Los resultados muestran una media de 5,32 s por consulta completa. T3 no es el cuello de botella: tarda de media 0,008 s, con unos 0,0042 s para calcular el embedding y 0,0039 s para búsqueda y fusión. El coste dominante está en las llamadas al LLM de T2 y T4. Esto encaja con la arquitectura: se prioriza seguridad lingüística y control de la respuesta, pero a costa de varias invocaciones generativas. En una versión de producción habría que estudiar cuantización, reducción de llamadas, prompts más breves o reutilización de salidas intermedias.

La medición confirma que añadir recuperación híbrida no compromete la viabilidad temporal de la PoC. Incluso separando el cálculo del embedding y la consulta a Weaviate, T3 representa una fracción mínima

Cuadro 11.2: Latencia agregada del ciclo T2–T4, en segundos.

Fase	Media	Mediana
T2a: normalización	1.138	1.090
T2b: traducción	0.890	0.895
T3: recuperación RAG	0.008	0.008
T4a: respuesta en inglés	1.626	1.920
T4b: adaptación a español	1.656	1.558
Total	5.318	5.531

del tiempo total. Esto desplaza el debate de optimización hacia la arquitectura generativa: la normalización, la traducción, la respuesta en inglés y la adaptación al español se ejecutan como llamadas separadas para mantener control y trazabilidad, pero podrían fusionarse parcialmente si el objetivo principal fuese reducir latencia.

11.3 | Ejemplos cualitativos

El caso exitoso más claro es la consulta “Cual es el motivo de la alarma 10655?”. T2a la normaliza como una pregunta sobre la causa técnica de la alarma 10655 y T2b la traduce a: *What is the technical cause that triggers the activation of alarm 10655...?*. T3 recupera el chunk exacto: 10655 [Channel%1:] Synchronization of gantry group%2 in progress. T4 responde que la alarma se activa cuando está en curso la sincronización del grupo gantry y conserva [REF:3]. La cadena, por tanto, mantiene el identificador, recupera evidencia adecuada y genera una respuesta breve.

Como fallo representativo, la consulta “Error 26120 en el eje, que hago ahora?” se normaliza y traduce correctamente manteniendo el código 26120, pero T3 recupera como primer resultado la sección 22296 Spindle Error on gear stage change, no la alarma solicitada. T4 genera una respuesta formalmente trazable con [REF:1], pero la referencia apunta a un fragmento incorrecto. El caso muestra que citar una referencia no garantiza la corrección: también debe verificarse que el fragmento citado corresponde a la necesidad informativa original.

Cuadro 11.3: Resumen cualitativo de dos ejecuciones completas.

Caso	T3	Efecto en T4
10655	Recupera el chunk esperado C000226 y conserva la sección de alarma.	La respuesta explica la causa y mantiene una referencia válida.
26120	Recupera una sección relacionada con husillo y cambio de etapa, no con el código pedido.	La respuesta parece correcta formalmente, pero se apoya en evidencia equivocada.

12 | Análisis de errores

El análisis de errores revela cinco patrones principales. El primero es la confusión entre alarmas de una misma familia técnica. Los recuperadores suelen identificar el área funcional correcta, pero fallan al elegir la alarma exacta. Esto ocurre cuando varias entradas comparten vocabulario, estructura y campos de remedio similares. En un manual industrial, esta confusión es especialmente peligrosa: una respuesta puede parecer plausible aunque esté asociada a un código distinto.

El segundo patrón es la reformulación léxica, que afecta sobre todo a BM25. Cuando la consulta usa expresiones diferentes a las del manual, los términos equivalentes desde el punto de vista semántico no siempre coinciden textualmente. Este resultado conecta directamente con la caracterización inicial del dominio: el operario usa lenguaje breve, contextual y a veces informal, mientras que el manual emplea formulaciones técnicas estables.

El tercer patrón es la atracción por fragmentos genéricos. BM25 puede priorizar secciones largas que contienen palabras frecuentes como *alarm*, *fault*, *channel* o *machine data*, aunque no contengan la evidencia concreta. El cuarto patrón aparece en la recuperación vectorial: al priorizar similitud semántica global,

puede desplazar identificadores exactos, códigos de alarma o nombres de parámetros. Por último, la recuperación híbrida hereda parte de ambos problemas. RRF mejora el equilibrio general, pero no elimina la ambigüedad cuando BM25 y el canal vectorial recuperan familias técnicas cercanas.

Estos errores muestran que la dificultad no es solo “entender” la consulta. En este dominio, entender también implica conservar con precisión identificadores formales. La PoC confirma que los embeddings ayudan ante reformulaciones, pero también que la coincidencia léxica sigue siendo necesaria. Una extensión natural sería incorporar un detector explícito de códigos de alarma o un re-ranking que penalice candidatos cuyo identificador no coincida con el de la consulta.

El análisis también revela una tensión propia de los sistemas RAG: aumentar el *top-k* da más oportunidades de incluir el fragmento correcto, pero también introduce más ruido para T4. En esta PoC se usa *top-k=5* como compromiso razonable. Un valor menor podría mejorar precisión si el recuperador acierta en primera posición, pero sería más frágil; un valor mayor podría elevar el *Hit Rate*, aunque aumentaría el riesgo de que el LLM se apoye en una referencia secundaria no pertinente. Por eso la mejora futura no debería limitarse a subir *K*, sino ordenar mejor los candidatos y filtrar incompatibilidades formales.

13 | Reflexión crítica

La PoC demuestra la viabilidad de T2–T4, pero queda lejos de un sistema industrial completo. En primer lugar, no incluye las etapas de voz. T1 debería reconocer habla en entornos ruidosos, con acentos y terminología híbrida; T5 debería sintetizar respuestas inteligibles y no solo convertir texto en audio. Además, una interfaz oral real tendría que gestionar repreguntas, interrupciones y peticiones de aclaración.

En segundo lugar, la evaluación de calidad sigue centrada en T3. La cadena T2–T4 se ha auditado mediante latencia y ejemplos cualitativos, pero no existe todavía una métrica automática de corrección final. En producción habría que evaluar fidelidad a la evidencia, ausencia de pasos inventados, utilidad operativa, conservación de referencias y adecuación al registro del operario. El caso fallido de 26120 muestra por qué: una respuesta puede sonar correcta y citar [REF:1], pero estar basada en una evidencia equivocada.

La trazabilidad también debe mejorar. Las etiquetas [REF:n] identifican la posición del fragmento recuperado en una consulta concreta, no una cita autosuficiente. En una interfaz de voz, el operario debería poder preguntar “léeme la referencia” o “de qué parte del manual sale eso”, y el sistema tendría que indicar manual, sección, alarma y fragmento relevante, idealmente traducido o resumido. La trazabilidad no debe ser solo interna para depuración, sino comprensible para el usuario final.

Otra limitación es documental: se usa un único manual de Siemens. Un despliegue real debería manejar varias versiones, equipos distintos, documentación heterogénea y posibles conflictos entre manuales. También habría que estudiar privacidad y trazabilidad de logs, porque en un entorno industrial real las consultas podrían revelar información operativa sensible.

Retrospectivamente, habría sido preferible definir antes el protocolo de evaluación, generar consultas más diversas desde el inicio y comparar estrategias adicionales como re-ranking o filtros exactos por código de alarma. Aun así, la PoC valida la idea central: una consulta breve en español puede normalizarse, traducirse, conectarse con documentación técnica en inglés y convertirse en una respuesta trazable. El salto a producción requeriría robustecer voz, evaluación integral, trazabilidad usable y escalabilidad documental.

En conjunto, el resultado más importante no es que el sistema responda siempre bien, sino que ya permite observar dónde falla cada componente. T2 puede evaluarse por conservación de códigos e intención; T3 por recuperación del chunk esperado; T4 por fidelidad a la evidencia; y la cadena completa por latencia y utilidad operativa. Esta separación hace que la arquitectura sea mejorable de forma incremental: se puede cambiar el chunking, sustituir el recuperador, añadir re-ranking o ajustar prompts sin rehacer todo el sistema.

14 | Referencias

- [1] BEIJING ACADEMY OF ARTIFICIAL INTELLIGENCE (BAAI). BAAI/bge-base-en-v1.5. <https://huggingface.co/BAAI/bge-base-en-v1.5>, 2023.
- [2] CORMACK, G. V., CLARKE, C. L. A., AND BUETTCHER, S. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd international ACM SIGIR conference on Research and development in information retrieval* (Boston MA USA, 2009), ACM, pp. 758–759.
- [3] GÜNTHER, M., ONG, J., MOHR, I., ABDESSALEM, A., ABEL, T., AKRAM, M. K., GUZMAN, S., MASTRAPAS, G., STURUA, S., WANG, B., WERK, M., WANG, N., AND XIAO, H. Jina embeddings 2: 8192-token general-purpose text embeddings for long documents. *arXiv preprint arXiv:2310.19923* (2023).
- [4] LEWIS, P., PEREZ, E., PIKTUS, A., PETRONI, F., KARPUKHIN, V., GOYAL, N., KÜTTLER, H., LEWIS, M., YIH, W., ROCKTÄSCHEL, T., RIEDEL, S., AND KIELA, D. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)* (2020).
- [5] LIU, A. H., KHANDLWAL, K., SUBRAMANIAN, S., JOUAULT, V., RASTOGI, A., SADÉ, A., ET AL. Ministral 3, 2026.
- [6] LLAMAINDEX. Llaparse. https://github.com/run-llama/llama_index, 2024.
- [7] MANNING, C. D., RAGHAVAN, P., AND SCHÜTZE, H. *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [8] ROBERTSON, S. E., WALKER, S., JONES, S., HANCOCK-BEAULIEU, M., AND GATFORD, M. Okapi at trec-3. In *Proceedings of the Third Text REtrieval Conference, TREC 1994, Gaithersburg, Maryland, USA, November 2-4, 1994* (1994), vol. 500-225 of *NIST Special Publication*, National Institute of Standards and Technology (NIST), pp. 109–126.
- [9] SIEMENS INDUSTRY ONLINE SUPPORT. SINUMERIK 808D ADVANCED Diagnostics Manual. <https://support.industry.siemens.com/cs/document/109759976/sinumerik-808d-advanced-diagnostics-manual>, 2018.